



SENAI – Serviço Nacional de Aprendizagem Industrial

**IMPLEMENTAÇÃO DE CLUSTER DE INTELIGÊNCIA  
ARTIFICIAL GENERATIVA NO SENAI Sesi/SC  
Projeto e Proposta para Parcerias**

Proposta para criação de infraestrutura física  
para cluster de Inteligência Artificial destinada  
ao ensino de Desenvolvimento de Sistemas e  
áreas correlatas no SENAI Sesi/SC .

Bruno José da Silva Batista  
Desenvolvedor de Software / Docente de Tecnologia  
bruno.batista@edu.sc.senai.br

Joinville / SC  
2026



# Sumário

|            |                                                                                  |           |
|------------|----------------------------------------------------------------------------------|-----------|
| <b>1</b>   | <b>INTRODUÇÃO . . . . .</b>                                                      | <b>5</b>  |
| <b>2</b>   | <b>OBJETIVOS . . . . .</b>                                                       | <b>6</b>  |
| <b>2.1</b> | <b>Objetivo Geral . . . . .</b>                                                  | <b>6</b>  |
| <b>2.2</b> | <b>Objetivos Específicos . . . . .</b>                                           | <b>6</b>  |
| <b>3</b>   | <b>ANÁLISE COMPARATIVA DE MODELOS DE INFRAESTRUTURA<br/>PARA LLM’S . . . . .</b> | <b>7</b>  |
| <b>3.1</b> | <b>API’s comerciais: ChatGPT, Claude, Gemini e afins . . . . .</b>               | <b>7</b>  |
| <b>3.2</b> | <b>LLM’s Open-Source Self-Hosted na AWS . . . . .</b>                            | <b>7</b>  |
| 3.2.1      | Demanda por Usuários . . . . .                                                   | 7         |
| 3.2.2      | Dimensionamento de Infra de GPU e Serviços Auxiliares On-Demand . . .            | 8         |
| <b>3.3</b> | <b>Cluster Próprio On-Premise . . . . .</b>                                      | <b>9</b>  |
| 3.3.1      | Especificação e Custo por Máquina . . . . .                                      | 9         |
| 3.3.2      | Blade Corporativo . . . . .                                                      | 9         |
| 3.3.3      | Capacidade Operacional . . . . .                                                 | 10        |
| <b>3.4</b> | <b>Conclusão da Análise Comparativa . . . . .</b>                                | <b>10</b> |
| <b>4</b>   | <b>BUSCA POR PARCERIAS PARA CONSTRUÇÃO DO CLUSTER ON-<br/>PREMISSE . . . . .</b> | <b>11</b> |
| <b>4.1</b> | <b>Divulgação Institucional . . . . .</b>                                        | <b>11</b> |
| <b>4.2</b> | <b>Portal de Gerenciamento de API Keys . . . . .</b>                             | <b>11</b> |
| <b>4.3</b> | <b>Impacto de Longo Prazo . . . . .</b>                                          | <b>12</b> |
| <b>5</b>   | <b>CONCLUSÃO . . . . .</b>                                                       | <b>13</b> |



# 1 Introdução

A Inteligência Artificial Generativa deixou de ser uma tecnologia emergente para se tornar um componente estrutural no processo contemporâneo de desenvolvimento de sistemas. Atualmente, Large Language Models (LLMs) são empregados em todas as fases do ciclo de vida do software:

- Levantamento e refinamento de requisitos
- Geração automatizada de código
- Criação de testes unitários
- Documentação técnica
- Revisão e refatoração de código
- Prototipagem rápida
- Desenvolvimento de APIs
- Automação de processos
- Construção de agentes inteligentes

Empresas globais incorporaram soluções baseadas em modelos de linguagem aos seus fluxos de engenharia, impactando produtividade, qualidade técnica e redução de tempo de entrega.

Para aproximadamente 10.000 alunos do SENAI Sesi/SC nas áreas de Desenvolvimento de Sistemas, Análise e Desenvolvimento de Sistemas, Tecnologia da Informação, Programação, Automação Industrial e áreas correlatas, a ausência de infraestrutura prática voltada ao uso de IA generativa pode tornar o processo formativo defasado frente às exigências do mercado.

O desenvolvedor contemporâneo precisa saber:

- Integrar APIs de LLM
- Construir agentes de IA
- Utilizar geração assistida de código
- Aplicar IA para debugging
- Trabalhar com RAG (Retrieval Augmented Generation)
- Projetar soluções híbridas entre software tradicional e IA

Este projeto visa garantir que o processo de formação permaneça alinhado à transformação digital já consolidada no setor produtivo.

## 2 Objetivos

### 2.1 Objetivo Geral

Implantar infraestrutura própria de IA generativa para criação de API keys educacionais destinadas à formação prática em desenvolvimento de sistemas.

### 2.2 Objetivos Específicos

- Prover ambiente controlado para uso de LLMs open-source
- Reduzir dependência de APIs comerciais
- Permitir uso educacional ilimitado
- Estimular desenvolvimento de agentes e aplicações reais
- Promover independência tecnológica institucional

# 3 Análise Comparativa de Modelos de Infra-estrutura para LLM's

Este capítulo apresenta análise comparativa entre três abordagens possíveis para disponibilização de Large Language Models (LLMs):

- Uso de API's comerciais
- LLM's open-source self-hosted na AWS
- Cluster próprio on-premise

## 3.1 API's comerciais: ChatGPT, Claude, Gemini e afins

API's comerciais apresenta estimativa média de R\$ 40 por aluno/mês.  
Considerando 10.000 alunos durante 12 meses, o custo anual estimado é de R\$ 1.440.000,00.

## 3.2 LLM's Open-Source Self-Hosted na AWS

Com LLMs open-source self-hosted o custo direto de utilização de APIs comerciais de modelos de linguagem é eliminado. Contudo, a utilização de GPUs sob demanda, aliada aos demais serviços da Amazon Web Services (AWS), torna a abordagem totalmente baseada em nuvem significativamente onerosa.

### 3.2.1 Demanda por Usuários

| Variável                     | Valor                             |
|------------------------------|-----------------------------------|
| Usuários                     | 10.000                            |
| Requests por dia por usuário | ~20                               |
| Volume mensal estimado       | ~1,8M requests                    |
| Tokens médios por request    | ~2.000 tokens                     |
| Custo de LLM externo         | US\$ 0                            |
| GPU necessária               | EC2 G5 / P4d (NVIDIA A10G / A100) |

### 3.2.2 Dimensionamento de Infra de GPU e Serviços Auxiliares On-Demand

| Modelo                    | VRAM necessária | Instância AWS               | Throughput |
|---------------------------|-----------------|-----------------------------|------------|
| Llama 3.1 8B (leve)       | ~16 GB          | g5.xlarge (1× A10G 24GB)    | ~800 tok/s |
| Llama 3.3 70B (principal) | ~140 GB         | g5.48xlarge (8× A10G)       | ~400 tok/s |
| DeepSeek R1 70B (distill) | ~140 GB         | g5.48xlarge (8× A10G)       | ~350 tok/s |
| DeepSeek R1 671B (full)   | ~320 GB+        | p4d.24xlarge (8× A100 80GB) | ~140 tok/s |

| Instância           | Uso                      | GPUs         | Custo/h    | Custo/mês              |
|---------------------|--------------------------|--------------|------------|------------------------|
| g5.48xlarge ×2      | Llama 70B + DeepSeek 70B | 8× A10G cada | ~US\$16,29 | ~US\$24.240            |
| g5.xlarge ×2        | Llama 8B (routing leve)  | 1× A10G cada | ~US\$1,006 | ~US\$1.497             |
| <b>Subtotal GPU</b> |                          |              |            | <b>~US\$25.737/mês</b> |

| Serviço                   | Custo estimado/mês  |
|---------------------------|---------------------|
| ECS Fargate (gateway)     | US\$ 60             |
| RDS PostgreSQL            | US\$ 130            |
| ElastiCache Redis         | US\$ 120            |
| API Gateway               | US\$ 6              |
| Application Load Balancer | US\$ 35             |
| CloudWatch + Logs         | US\$ 60             |
| Secrets Manager           | US\$ 5              |
| NAT Gateway               | US\$ 70             |
| S3 (modelos + logs)       | US\$ 80             |
| <b>Subtotal suporte</b>   | <b>~US\$566/mês</b> |

| Categoria                | Custo estimado/mês     |
|--------------------------|------------------------|
| Infra base (CPU/rede/DB) | ~US\$566               |
| GPU (inference)          | ~US\$25.737            |
| <b>Total on-demand</b>   | <b>~US\$26.303/mês</b> |



### 3.3 Cluster Próprio On-Premise

A proposta central deste projeto consiste na aquisição de infraestrutura própria composta por quatro servidores GPU de alto desempenho e blade corporativo de orquestração. A infraestrutura proposta é composta por:

- 4 servidores GPU de alto desempenho
- 1 blade corporativo para orquestração
- Balanceamento de carga
- Backend com LLMs open-source
- Portal próprio para geração de API keys

Especificações principais:

- AMD Ryzen Threadripper PRO 7965WX
- ASUS Pro WS WRX90E-SAGE
- 7× NVIDIA GeForce RTX 4090 Gaming OC 24GB por máquina

#### 3.3.1 Especificação e Custo por Máquina

| Componente               | Valor Estimado        |
|--------------------------|-----------------------|
| CPU                      | R\$ 23.000,00         |
| Placa-mãe                | R\$ 16.600,00         |
| 7 GPUs                   | R\$ 72.000,00         |
| RAM 256GB                | R\$ 30.000,00         |
| Armazenamento            | R\$ 15.000,00         |
| Infraestrutura elétrica  | R\$ 8.000,00          |
| <b>Total por máquina</b> | <b>R\$ 164.600,00</b> |

**Investimento total (4 máquinas): R\$ 658.400,00.**

#### 3.3.2 Blade Corporativo

Integração com soluções como IBM BladeCenter, Hewlett Packard Enterprise ou Dell Technologies.

Estimativa: R\$ 90.000,00 a R\$ 120.000,00.

**Investimento total estimado do projeto: aproximadamente R\$ 750.000,00.**

### 3.3.3 Capacidade Operacional

Cada servidor com quatro RTX 4090 permite aproximadamente 150 usuários simultâneos (modelo Llama3 13B) ou até 180 usuários simultâneos (modelo Llama3 7B).

Cluster com quatro máquinas: capacidade estimada entre 600 e 720 usuários simultâneos.

Considerando simultaneidade média de 20% a 25% em ambiente educacional, a capacidade é adequada para atender 10.000 alunos.

**Payback estimado: 12 meses.**

## 3.4 Conclusão da Análise Comparativa

Embora a abordagem com LLMs open-source self-hosted elimine o custo direto de APIs comerciais, a dependência de GPUs de alto desempenho sob demanda na AWS gera custo mensal estimado superior a US\$ 26.000. Em termos anuais, essa estrutura ultrapassa US\$ 315.000, mantendo dependência integral de infraestrutura cloud e variação cambial. Dentre todos os cenários, o da implantação do cluster próprio on-premise se destaca tanto pela amortização - que ocorre em prazo inferior a 12 meses com investimento aproximado de R\$ 750.000,00 - quanto pela comparação aos modelos baseados em APIs comerciais e ao modelo integralmente hospedado em nuvem.

Vale salientar que do ponto de vista estratégico, institucional e financeiro, o modelo on-premise apresenta o melhor equilíbrio entre:

- Sustentabilidade econômica
- Independência tecnológica
- Capacidade de expansão futura
- Posicionamento institucional como referência em inovação

## 4 Busca por parcerias para construção do Cluster On-Premisse

Como observado, o modelo on-premise apresenta vantagens estratégicas. Não só para a instituição, mas também para empresas parceiras. Esse capítulo elenca algumas possíveis estratégias para a criação de incentivos às parcerias. O projeto de infraestrutura prevê uma identidade visual do cluster como:

***“Cluster IA Generativa – Powered by [Empresa Parceira]”.***

Outras abordagens convidativas está a identificação visual que ocorrerá:

- No ambiente físico
- No portal de APIs do Cluster
- Em comunicações institucionais
- Em eventos técnicos

### 4.1 Divulgação Institucional

Divulgação por meio do portal institucional do SENAI SC, portais regionais, comunicados ao setor industrial, eventos tecnológicos e redes sociais oficiais.

### 4.2 Portal de Gerenciamento de API Keys

Será desenvolvido portal dedicado para geração de API keys, monitoramento de uso, documentação técnica e dashboard de consumo.

O portal contará com:

- Co-branding institucional
- Logotipo da empresa parceira
- Reconhecimento formal da parceria

Cada aluno terá contato recorrente com a marca durante sua formação. Esse mecanismo promove:

- Exposição contínua
- Fortalecimento de marca

- Remarketing orgânico
- Associação direta com inovação

### 4.3 Impacto de Longo Prazo

Os 10.000 alunos anuais representam futuros:

- Desenvolvedores
- Arquitetos de software
- Líderes técnicos
- Empreendedores
- Decisores de compra

A presença institucional da empresa parceira durante a formação desses profissionais cria vínculo estratégico duradouro.

## 5 Conclusão

A Inteligência Artificial Generativa já integra o processo moderno de desenvolvimento de sistemas. Não preparar os alunos para utilizar essas ferramentas de maneira técnica e estratégica compromete a aderência do processo educacional às exigências do mercado.

O cluster próprio de IA generativa:

- Atualiza o ambiente formativo
- Garante independência tecnológica
- Proporciona economia estrutural
- Sustenta crescimento futuro
- Consolida posicionamento institucional

Do ponto de vista financeiro, o investimento apresenta racional claro, com payback inferior a 12 meses quando comparado ao custo recorrente de APIs comerciais. Do ponto de vista estratégico, assegura alinhamento com a transformação digital da indústria.

Para a empresa parceira, o projeto oferece:

- Visibilidade estadual
- Associação direta com inovação
- Exposição contínua a 10.000 alunos por ano
- Inserção no ecossistema industrial catarinense
- Posicionamento como protagonista em educação tecnológica

A decisão de implantar o cluster não é apenas técnica ou financeira. É estratégica. Ela garante que o SENAI Santa Catarina continue formando profissionais preparados para um mercado no qual a IA generativa já é parte integrante da engenharia de software.